

Assignment #3

1. 과제에 사용한 데이터셋은 Fashion-MNIST를 사용하였는데, Marabou에서 MNIST 데이터셋과, ACAS XU, CollisionAvoidance, TwinStreams 등의 벤치마크가 제공되지만, Fashion-MNIST에 대해서는 검증한 것이 없어서 MNIST 환경보다 정확하게 맞추기 조금 더 어려운 Fashion-MNIST에 대해서 검증을 시도하였다. 다만 이에 대해 학습하는 모델은 2개의 layer로 되어있는 MLP 모델을 사용하였다. CNN 모델을 사용하려는 계획은 있었으나, 모델 설계하기 전, Marabou에서 제공된 CNN 모델을 통해, 쿼리를 통해 검증을 하였을 때, runtime이 오래 걸리는 것을 확인하여서, 이를 피하고자, 간단하게 MLP 모델로 만들었다. 실험 과정에서 epsilon에 따른 국소적 강건성을 보기 위해서, epsilon을 입력으로 주게끔 하여서, 원본 이미지로부터 epsilon만큼 거리 차가 나는 이미지를 통해 모델의 예측 결과가 뒤바뀌는 입력값이 존재하는 지를 확인하는 쿼리를 넣었다. 이 때, 입력 제약 조건으로 원본 이미지와 각 픽셀에 대한 거리 차를 과제에서는 L infinite 놔로 설정 해놨다.


그리고 출력에 대해서 원본 클래스와 목표 클래스와 같게 예측하는 지점이 있는 확인하기 위해서 출력(원본 클래스) - 출력(목표 클래스) ≤ 0 으로 설정해놨다. 이때 결과적으로 SAT이 나오면 부등식을 만족하기 때문에, 엡실론안으로 목표 클래스를 오분류하는 적대적 예제가 존재한다. 만약 UNSAT일 경우에는 적대적 예제가 존재하지 않으므로 국소적 강건성을 가지게 된다.

1. Marabou 솔버를 통해, 1번에 나온 쿼리를 가지고 두 층의 선형 모델의 국소적 강건성을 증명하였다. 전체 데이터셋 중 임의의 데이터의 라벨은 9번이었고, 이에 대해 목표 클래스를 0으로 설정하고 epsilon 크기에 따라 결과를 분석하였다.

입력 제한(ϵ)	결과	검증 시간 (sec)	최대 메모리 (KB)	강건성 상태
0.1	SAT	0.0993	741,544	취약함 (Not Robust)
0.01	UNSAT	0.0359	713,220	강건함 (Robust)

ϵ 이 0.1인 경우, marabou는 SAT 결과를 반환하였는데, 이는 모델의 강건성이 안되는 지점이 있다는 것을 증명했다.

이 경우, 반례를 발견한 것인데, 반례의 경우는 입력에 대해 어느 특정 픽셀을 미세하게



조정해서 모델의 출력을 변화시키는 것인데, 다음 이미지가, 적대적 예제가 된다.

하지만 epsilon이 0.1로 사람 눈에 구별하기엔 큰 편이 아니기 때문에, 큰 차이를 볼 수 있다.

ϵ 이 0.01인 경우는 UNSAT 결과가 나왔다. 이는 해당 범위에서는 클래스를 0으로 오분류시키는 입력값이 존재하지 않다는 것을 수학적으로 보증한다.

3. Marabou라는 솔버를 처음 써보면서, 이렇게 강건성을 증명하는 방법도 있는 것에
신기했으며, 또 한편으로는 솔버를 분석하면서 onnx나, nnex와 같은 처음 보는 포맷에 대해
공부를 할 수 있었던 것 같다. marabou를 분석하면서, 사용법보다 marabou 안의
작동방식을 공부하는 것이 더 오래 걸렸는데, 사용법이 office document나 example로
표현이 잘 되어 있어서 아마 사용법을 금방 익힌 것이 아닌가 싶다. 간단한 모델의 경우에는
정말로 탐지 속도가 빨랐는데, 2번 실험을 거치는 과정에서는 내 결과에는 각각 메모리
크기가 740MB, 713MB로 크게 나타난 것을 볼 수 있다. 이 솔버만 메모리를 크게 먹는
것인지, 아니면 다른 솔버도 크게 메모리를 먹는 것인지는 다른 솔버들을 써봐야 알 수
있지만, 우선 이 솔버만 봤을 때, Marabou가 네트워크를 검증하는 과정에서 메모리를 크게
잡아먹는다고 판단이 된다.

마지막으로 marabou가 단점만 있었던 것은 아니고, 다양한 포맷을 제공해주고, 쿼리만
금방 바꾸면 바로 검증을 돌릴 수 있는 점도 장점이라고 볼 수 있는 것 같다.